基于ResNet模型对Caltech-101进行图像分类

运行

更新于 2020-08-24 11:36:51 1 1

图像分类，是根据数据中反映的不同特征，区分属于不同类别的图像。 本案例中，我们将采用ResNet模型，使用PyTorch，对Caltech-101数据集进行图像分类，分类准确率稳定在95%左右。

目录


```
import matplotlib.pyplot as plt
import matplotlib
import argparse
import joblib
```

```
import cv2
import os
import torch
import numpy as np
import torch.nn as nn
import torch.nn.functional as F
import torch.optim as optim
import time
import pickle
import random
import pretrainedmodels
import torchvision

matplotlib.style.use('ggplot')

from imutils import paths
from sklearn.preprocessing import LabelBinarizer
from sklearn.model_selection import train_test_split
from sklearn.metrics import classification_report
from torchvision.transforms import transforms
from torch.utils.data import DataLoader, Dataset
from torchvision import models
from tqdm import tqdm
```

1 数据集简介

Caltech-101数据集大小为132MB，包含101类物体图片，和1个杂乱类（background）。数据集中已经标注了图像所属的类别，主要用于目标识别和图像分类。

本案例中，不采用杂乱类，采用其余101类物体图片进行训练。总共包含8677幅图像，其中每个类别包含不同角度、背景、光照下获得的40到800张图像，每张图像的大小不完全相同，基本在300 ×200 像素左右。

如下图所示，101类物体涵盖的范围很广泛，包括多个领域的物体。如生物类有蝴蝶、海马，植物类有向日葵、荷花，工具类有照相机、手机等等。


2 划分数据集

2.1 分析数据集

首先读取Caltech-101数据集，并且处理数据集，即提取出图像及其对应的类别，相匹配并保存在变量中。

tar是文件打包工具，可以将多个文件合并为一个文件。打包后的文件名后缀为 `tar` ，后缀为 `tar` 的文件代表未被压缩的tar文件。已被压缩的tar文件则需要追加压缩文件的扩展名，如经过gzip压缩后的tar文件，扩展名变 `tar.gz` 。

```
import tarfile
with tarfile.open('/content/101_ObjectCategories.tar.gz', 'r:gz') as tar:
    tar.extractall()
```

```
image_paths = list(paths.list_images('/content/101_ObjectCategories'))
data = []
labels = []
label_names = []
for image_path in image_paths:
    label = image_path.split(os.path.sep)[-2]

    # 删去杂乱类
    if label == 'BACKGROUND_Google':
        continue

    image = cv2.imread(image_path)
    image = cv2.cvtColor(image, cv2.COLOR_BGR2RGB)

    data.append(image)
    label_names.append(label)
    labels.append(label)
```

```
data = np.array(data)
labels = np.array(labels)
```

```
# 图像的类别
lb = LabelBinarizer()
labels = lb.fit_transform(labels)
print("数据集共有",len(lb.classes_),"类")

# 储存图像类别的名称
count_arr = []
label_arr = []
for i in range(len(lb.classes_)):
    count = 0
    for j in range(len(label_names)):
        if lb.classes_[i] in label_names[j]:
            count += 1
    count_arr.append(count)
    label_arr.append(lb.classes_[i])
```

数据集共有 101 类

下图为101类中，每个类别包含的图片数量。我们可以直观感受到，数据集存在两个问题：

（1）数据集不平衡。人脸数据集包含的图像最多，约900张，而很多数据集只包含40张左右的图像。

（2）数据集较小。从图中可以看到，很多类别包含的图像数量很少，只有40-100张左右。

```
plt.figure(figsize=(18, 15))
plt.bar(label_arr, count_arr,color="cadetblue")
plt.xticks(rotation='vertical')
plt.show()
```

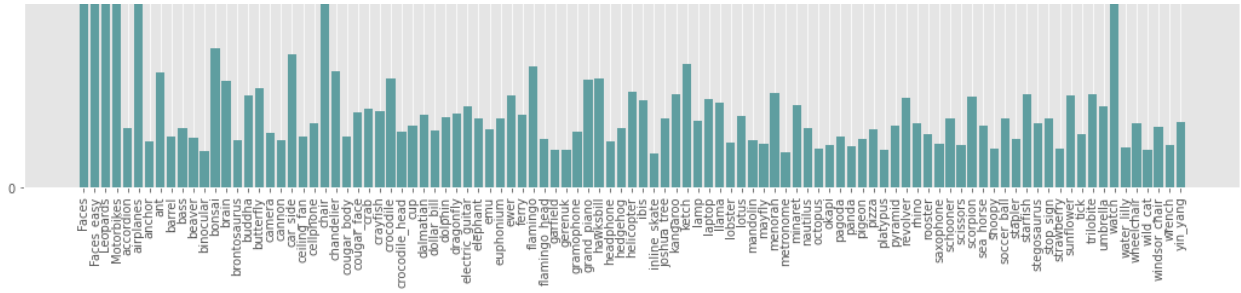

数据集不平衡和数据集小可能造成神经网络训练结果不理想。

本案例中使用微调和迁移学习，克服数据集不平衡的问题，达到95%的分类准确率。解决数据集不平衡的常用方法，还有使用图像增强，以增加图片的数量，感兴趣的读者可以进行尝试。

2.2 划分训练集、验证集和测试集

接下来，我们调用sklearn库中的 `train_test_split` 函数，来划分数据集。划分比例为，训练集：验证集：测试集 = 3:1:1。

```
(X, x_val , Y, y_val) = train_test_split(data, labels,
                                                    test_size=0.2,
                                                    stratify=labels,
                                                    random_state=42)

(x_train, x_test, y_train, y_test) = train_test_split(X, Y,
                                                    test_size=0.25,
                                                    random_state=42)

print(f"训练集 x_train 图片数 : {x_train.shape}\n验证集 x_test 图片数: {x_test.shape}\n测试集 x_val 图片数: {x_val.shape}")
```

```
训练集 x_train 图片数 : (5205,)
验证集 x_test 图片数: (1736,)
测试集 x_val 图片数: (1736,)
```

模型训练中，图像的格式需要一致。因此我们定义图像格式转换函数，将图像调整为224×224像素，并将原数据格式转换为tensor形式，并对其进行标准化。标准化图像所需的参数，来源于在ImageNet上预训练得到的参数。

下列代码进行了上述的格式转换，这里我们分开定义训练集和验证集。这样当我们想对训练集和验证集进行不同的操作时，更加方便明了。

```
# 定义格式转换函数
```

```
# 定义格式转换函数
train_transform = transforms.Compose(
    [transforms.ToPILImage(),
     transforms.Resize((224, 224)),
     transforms.ToTensor(),
     transforms.Normalize(mean=[0.485, 0.456, 0.406],
                          std=[0.229, 0.224, 0.225])])
val_transform = transforms.Compose(
    [transforms.ToPILImage(),
     transforms.Resize((224, 224)),
     transforms.ToTensor(),
     transforms.Normalize(mean=[0.485, 0.456, 0.406],
                          std=[0.229, 0.224, 0.225])])
```

接下来我们调用刚才定义的格式转换函数，将训练集、验证集、测试集都进行格式转换，并保存下来，在训练模型的时候调用。

```
# 转换并保存训练集、验证集、测试集
class ImageDataset(Dataset):
    def __init__(self, images, labels=None, transforms=None):
        self.X = images
        self.y = labels
        self.transforms = transforms

    def __len__(self):
        return (len(self.X))

    def __getitem__(self, i):
        data = self.X[i][:]

        if self.transforms:
            data = self.transforms(data)

        if self.y is not None:
            return (data, self.y[i])
        else:
            return data

train_data = ImageDataset(x_train, y_train, train_transform)
val_data = ImageDataset(x_val, y_val, val_transform)
test_data = ImageDataset(x_test, y_test, val_transform)
```

获取训练集、验证集和测试集后，我们使用 `Dataloader` 函数载入和遍历数据集。定义训练模型时每个批次（batch）的大小为16张图像； `shuffle=True` 保证在每次提取了所有数据后（即一个epoch后），打乱数据集，重新提取下一个epoch中每个批次（batch）的数据。

`epochs` 代表对所有样本进行训练的次数， `batch_size` 指一次一起训练的样本的数

量。考虑到运行时间和内存大小，本案例中进行如下定义。

```
epochs = 5
batch_size = 16
```

```
# 数据集 dataloaders
trainloader = DataLoader(train_data, batch_size=16, shuffle=True)
valloader = DataLoader(val_data, batch_size=16, shuffle=True)
testloader = DataLoader(test_data, batch_size=16, shuffle=False)
```

划分好数据集后，我们定义函数随机抽取现有的训练集，观察图像，并确认其大小一致。

```
def imshow(img):
    plt.figure(figsize=(15, 12))
    img = img / 2 + 0.5
    npimg = img.numpy()
    plt.imshow(np.transpose(npimg, (1, 2, 0)))

    plt.show()


# 随机获取一些图像
dataiter = iter(trainloader)
images, labels = dataiter.next()

# 显示图像
imshow(torchvision.utils.make_grid(images))
```

```
Clipping input data to the valid range for imshow with RGB data ([0..1] for fl
oats or [0..255] for integers).
```

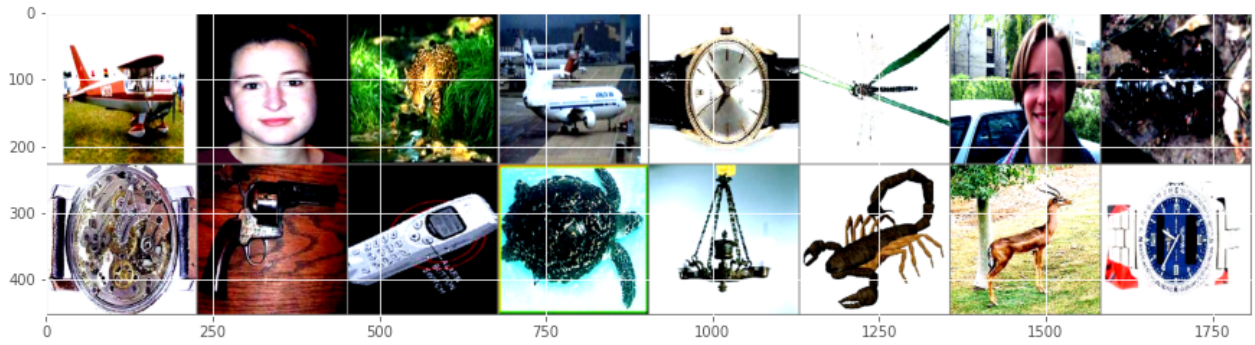

3 建立ResNet模型

接下来我们将构建ResNet模型。

3.1 定义模型初始参数

首先设置随机种子，以使读者在运行时能够获得与本文一致的运行结果，使于理解文中对运行结果的分析。

```
# 定义随机种子
def seed_everything(SEED=42):
    random.seed(SEED)
    np.random.seed(SEED)
    torch.manual_seed(SEED)
    torch.cuda.manual_seed(SEED)
    torch.cuda.manual_seed_all(SEED)
    torch.backends.cudnn.deterministic = True # 所有的图像大小相同，所以参数可以为True
SEED=42
seed_everything(SEED=SEED)
```

相比于CPU，使用GPU训练模型，能够大大减少训练时间，下列代码能够让程序调用GPU训练模型。

```
if torch.cuda.is_available():
    device = 'cuda'
else:
    device = 'cpu'
```

3.2 构建ResNet的网络结构

接下来构建ResNet的网络结构。

为了减少模型的训练时间，以及考虑到数据集较少，可能会影响训练结果，我们使用在ImageNet上训练后得到的参数，在Caltech-101数据集上训练，进行微调，得到训练结果。

因为神经网络在提取特征时，前面的层所提取的特征更具一般性，后面的层则更加具体，更具有原始数据集的特征。又考虑到Caltech-101数据集较小，且与ImageNet的相似程度不高，我们微调ResNet较前面的层。

除了进行微调以外，我们还加入Dropout层，避免模型过拟合。

```
class ResNet34(nn.Module):
    def __init__(self, pretrained):
        # 调用在ImagetNet上预训练的ResNet模型的权重
        super(ResNet34, self).__init__()
        if pretrained is True:
            self.model = pretrainedmodels.__dict__['resnet34'](pretrained='imagenet')
        else:
```

```
            self.model = pretrainedmodels.__dict__['resnet34'](pretrained=None
)

        # 改变全连接层的输出
        self.l0 = nn.Linear(512, len(lb.classes_))
        # 设置dropout层的参数
        self.dropout = nn.Dropout2d(0.4)

    # 对在ImageNet上训练得到的ResNet模型进行微调
    def forward(self, x):
        # 得到图像数据
        batch, _, _, _ = x.shape
        x = self.model.features(x)
        x = F.adaptive_avg_pool2d(x, 1).reshape(batch, -1)
        # 在全连接层前接入Dropout层
        x = self.dropout(x)
        # 连接全连接层
        l0 = self.l0(x)
        return l0

# 显示模型构造
model = ResNet34(pretrained=True).to(device)
print(model)
```

```
Downloading: "https://download.pytorch.org/models/resnet34-333f7ec4.pth" to /r
oot/.cache/torch/hub/checkpoints/resnet34-333f7ec4.pth


ResNet34(
  (model): ResNet(
    (conv1): Conv2d(3, 64, kernel_size=(7, 7), stride=(2, 2), padding=(3, 3),
bias=False)
    (bn1): BatchNorm2d(64, eps=1e-05, momentum=0.1, affine=True, track_running
_stats=True)
    (relu): ReLU(inplace=True)
    (maxpool): MaxPool2d(kernel_size=3, stride=2, padding=1, dilation=1, ceil_
mode=False)
    (layer1): Sequential(
      (0): BasicBlock(
        (conv1): Conv2d(64, 64, kernel_size=(3, 3), stride=(1, 1), padding=(1,
1), bias=False)
        (bn1): BatchNorm2d(64, eps=1e-05, momentum=0.1, affine=True, track_run
ning_stats=True)
        (relu): ReLU(inplace=True)
        (conv2): Conv2d(64, 64, kernel_size=(3, 3), stride=(1, 1), padding=(1,
1), bias=False)
        (bn2): BatchNorm2d(64, eps=1e-05, momentum=0.1, affine=True, track_run
ning_stats=True)
      )
      (1): BasicBlock(
        (conv1): Conv2d(64, 64, kernel_size=(3, 3), stride=(1, 1), padding=(1,
1), bias=False)
        (bn1): BatchNorm2d(64, eps=1e-05, momentum=0.1, affine=True, track_run
ning_stats=True)
        (relu): ReLU(inplace=True)
        (conv2): Conv2d(64, 64, kernel_size=(3, 3), stride=(1, 1), padding=(1,
```

```
1), bias=False)
        (bn2): BatchNorm2d(64, eps=1e-05, momentum=0.1, affine=True, track_run
ning_stats=True)
      )
      (2): BasicBlock(
        (conv1): Conv2d(64, 64, kernel_size=(3, 3), stride=(1, 1), padding=(1,
1), bias=False)
        (bn1): BatchNorm2d(64, eps=1e-05, momentum=0.1, affine=True, track_run
ning_stats=True)
        (relu): ReLU(inplace=True)
        (conv2): Conv2d(64, 64, kernel_size=(3, 3), stride=(1, 1), padding=(1,
1), bias=False)
        (bn2): BatchNorm2d(64, eps=1e-05, momentum=0.1, affine=True, track_run
ning_stats=True)
      )
    )
    (layer2): Sequential(
      (0): BasicBlock(
        (conv1): Conv2d(64, 128, kernel_size=(3, 3), stride=(2, 2), padding=
(1, 1), bias=False)
        (bn1): BatchNorm2d(128, eps=1e-05, momentum=0.1, affine=True, track_ru
nning_stats=True)
        (relu): ReLU(inplace=True)
        (conv2): Conv2d(128, 128, kernel_size=(3, 3), stride=(1, 1), padding=
(1, 1), bias=False)
        (bn2): BatchNorm2d(128, eps=1e-05, momentum=0.1, affine=True, track_ru
nning_stats=True)
        (downsample): Sequential(
          (0): Conv2d(64, 128, kernel_size=(1, 1), stride=(2, 2), bias=False)
          (1): BatchNorm2d(128, eps=1e-05, momentum=0.1, affine=True, track_ru
nning_stats=True)
        )
      )
      (1): BasicBlock(
        (conv1): Conv2d(128, 128, kernel_size=(3, 3), stride=(1, 1), padding=
(1, 1), bias=False)
        (bn1): BatchNorm2d(128, eps=1e-05, momentum=0.1, affine=True, track_ru
nning_stats=True)
        (relu): ReLU(inplace=True)
        (conv2): Conv2d(128, 128, kernel_size=(3, 3), stride=(1, 1), padding=
(1, 1), bias=False)
        (bn2): BatchNorm2d(128, eps=1e-05, momentum=0.1, affine=True, track_ru
nning_stats=True)
      )
      (2): BasicBlock(
        (conv1): Conv2d(128, 128, kernel_size=(3, 3), stride=(1, 1), padding=
(1, 1), bias=False)
        (bn1): BatchNorm2d(128, eps=1e-05, momentum=0.1, affine=True, track_ru
nning_stats=True)
        (relu): ReLU(inplace=True)
        (conv2): Conv2d(128, 128, kernel_size=(3, 3), stride=(1, 1), padding=
(1, 1), bias=False)
        (bn2): BatchNorm2d(128, eps=1e-05, momentum=0.1, affine=True, track_ru
nning_stats=True)
      )
```

```
      (3): BasicBlock(
        (conv1): Conv2d(128, 128, kernel_size=(3, 3), stride=(1, 1), padding=
(1, 1), bias=False)
        (bn1): BatchNorm2d(128, eps=1e-05, momentum=0.1, affine=True, track_ru
nning_stats=True)
        (relu): ReLU(inplace=True)
        (conv2): Conv2d(128, 128, kernel_size=(3, 3), stride=(1, 1), padding=
(1, 1), bias=False)
        (bn2): BatchNorm2d(128, eps=1e-05, momentum=0.1, affine=True, track_ru
nning_stats=True)
      )
    )
    (layer3): Sequential(
      (0): BasicBlock(
        (conv1): Conv2d(128, 256, kernel_size=(3, 3), stride=(2, 2), padding=
(1, 1), bias=False)
        (bn1): BatchNorm2d(256, eps=1e-05, momentum=0.1, affine=True, track_ru
nning_stats=True)
        (relu): ReLU(inplace=True)
        (conv2): Conv2d(256, 256, kernel_size=(3, 3), stride=(1, 1), padding=
(1, 1), bias=False)
        (bn2): BatchNorm2d(256, eps=1e-05, momentum=0.1, affine=True, track_ru
nning_stats=True)
        (downsample): Sequential(
          (0): Conv2d(128, 256, kernel_size=(1, 1), stride=(2, 2), bias=False)
          (1): BatchNorm2d(256, eps=1e-05, momentum=0.1, affine=True, track_ru
nning_stats=True)
        )
      )
      (1): BasicBlock(
        (conv1): Conv2d(256, 256, kernel_size=(3, 3), stride=(1, 1), padding=
(1, 1), bias=False)
        (bn1): BatchNorm2d(256, eps=1e-05, momentum=0.1, affine=True, track_ru
nning_stats=True)
        (relu): ReLU(inplace=True)
        (conv2): Conv2d(256, 256, kernel_size=(3, 3), stride=(1, 1), padding=
(1, 1), bias=False)
        (bn2): BatchNorm2d(256, eps=1e-05, momentum=0.1, affine=True, track_ru
nning_stats=True)
      )
      (2): BasicBlock(
        (conv1): Conv2d(256, 256, kernel_size=(3, 3), stride=(1, 1), padding=
(1, 1), bias=False)
        (bn1): BatchNorm2d(256, eps=1e-05, momentum=0.1, affine=True, track_ru
nning_stats=True)
        (relu): ReLU(inplace=True)
        (conv2): Conv2d(256, 256, kernel_size=(3, 3), stride=(1, 1), padding=
(1, 1), bias=False)
        (bn2): BatchNorm2d(256, eps=1e-05, momentum=0.1, affine=True, track_ru
nning_stats=True)
      )
      (3): BasicBlock(
        (conv1): Conv2d(256, 256, kernel_size=(3, 3), stride=(1, 1), padding=
(1, 1), bias=False)
        (bn1): BatchNorm2d(256, eps=1e-05, momentum=0.1, affine=True, track_ru
```

```
nning_stats=True)
        (relu): ReLU(inplace=True)
        (conv2): Conv2d(256, 256, kernel_size=(3, 3), stride=(1, 1), padding=
(1, 1), bias=False)
        (bn2): BatchNorm2d(256, eps=1e-05, momentum=0.1, affine=True, track_ru
nning_stats=True)
      )
      (4): BasicBlock(
        (conv1): Conv2d(256, 256, kernel_size=(3, 3), stride=(1, 1), padding=
(1, 1), bias=False)
        (bn1): BatchNorm2d(256, eps=1e-05, momentum=0.1, affine=True, track_ru
nning_stats=True)
        (relu): ReLU(inplace=True)
        (conv2): Conv2d(256, 256, kernel_size=(3, 3), stride=(1, 1), padding=
(1, 1), bias=False)
        (bn2): BatchNorm2d(256, eps=1e-05, momentum=0.1, affine=True, track_ru
nning_stats=True)
      )
      (5): BasicBlock(
        (conv1): Conv2d(256, 256, kernel_size=(3, 3), stride=(1, 1), padding=
(1, 1), bias=False)
        (bn1): BatchNorm2d(256, eps=1e-05, momentum=0.1, affine=True, track_ru
nning_stats=True)
        (relu): ReLU(inplace=True)
        (conv2): Conv2d(256, 256, kernel_size=(3, 3), stride=(1, 1), padding=
(1, 1), bias=False)
        (bn2): BatchNorm2d(256, eps=1e-05, momentum=0.1, affine=True, track_ru
nning_stats=True)
      )
    )
    (layer4): Sequential(
      (0): BasicBlock(
        (conv1): Conv2d(256, 512, kernel_size=(3, 3), stride=(2, 2), padding=
(1, 1), bias=False)
        (bn1): BatchNorm2d(512, eps=1e-05, momentum=0.1, affine=True, track_ru
nning_stats=True)
        (relu): ReLU(inplace=True)
        (conv2): Conv2d(512, 512, kernel_size=(3, 3), stride=(1, 1), padding=
(1, 1), bias=False)
        (bn2): BatchNorm2d(512, eps=1e-05, momentum=0.1, affine=True, track_ru
nning_stats=True)
        (downsample): Sequential(
          (0): Conv2d(256, 512, kernel_size=(1, 1), stride=(2, 2), bias=False)
          (1): BatchNorm2d(512, eps=1e-05, momentum=0.1, affine=True, track_ru
nning_stats=True)
        )
      )
      (1): BasicBlock(
        (conv1): Conv2d(512, 512, kernel_size=(3, 3), stride=(1, 1), padding=
(1, 1), bias=False)
        (bn1): BatchNorm2d(512, eps=1e-05, momentum=0.1, affine=True, track_ru
nning_stats=True)
        (relu): ReLU(inplace=True)
        (conv2): Conv2d(512, 512, kernel_size=(3, 3), stride=(1, 1), padding=
(1, 1), bias=False)
```

```
        (bn2): BatchNorm2d(512, eps=1e-05, momentum=0.1, affine=True, track_ru
nning_stats=True)
      )
      (2): BasicBlock(
        (conv1): Conv2d(512, 512, kernel_size=(3, 3), stride=(1, 1), padding=
(1, 1), bias=False)
        (bn1): BatchNorm2d(512, eps=1e-05, momentum=0.1, affine=True, track_ru
nning_stats=True)
        (relu): ReLU(inplace=True)
        (conv2): Conv2d(512, 512, kernel_size=(3, 3), stride=(1, 1), padding=
(1, 1), bias=False)
        (bn2): BatchNorm2d(512, eps=1e-05, momentum=0.1, affine=True, track_ru
nning_stats=True)
      )
    )
    (avgpool): AdaptiveAvgPool2d(output_size=(1, 1))
    (fc): None
    (last_linear): Linear(in_features=512, out_features=1000, bias=True)
  )
  (10): Linear(in_features=512, out_features=101, bias=True)
  (dropout): Dropout2d(p=0.4, inplace=False)
)
```

同时，我们需要为模型选择合适的参数优化算法和损失函数。我们选择Adam优化算法。它是随机梯度下降法的扩展，和随机梯度下降法的不同之处在于：随机梯度下降法中保持单一的学习率（alpha），来更新所有的权重，即学习率在训练过程中并不会改变。但Adam优化算法通过计算梯度的一阶矩估计和二阶矩估计，为不同的参数选择独立的自适应性学习率。

另外，我们定义损失函数为交叉熵损函数。交叉熵主要刻画的是实际输出概率与期望输出概率的差值，即交叉熵的值越小，表明两个概率分布就越接近。

```
# 定义优化参数的方法
optimizer = optim.Adam(model.parameters(), lr=1e-4)
# 定义损失函数
criterion = nn.CrossEntropyLoss()
```

3.3 定义训练、验证函数

定义了ResNet模型构造后，接下来需要定义训练模型和验证模型的函数。

首先定义训练模型的函数，函数需要实现计算分类准确率、损失值、通过反向传播优化参数等功能。

```
# 训练函数
def fit(model, dataloader):
    print('训练')
```

```
    print('训练')
    model.train()
    train_running_loss = 0.0
    train_running_correct = 0
    # 对每个批次（batch）进行训练
    for i, data in tqdm(enumerate(dataloader), total=int(len(train_data)/data
loader.batch_size)):
        data, target = data[0].to(device), data[1].to(device)

        # 梯度值更新为零
        optimizer.zero_grad()
        outputs = model(data)

        # 计算损失值
        loss = criterion(outputs, torch.max(target, 1)[1])
        train_running_loss += loss.item()

        # 得到分类结果
        _, preds = torch.max(outputs.data, 1)
        train_running_correct += (preds == torch.max(target, 1)[1]).sum().item
()

        # 通过反向传播更新参数
        loss.backward()
        optimizer.step()

    # 每次训练完所有数据（一次epoch）后，计算损失值和分类准确率
    train_loss = train_running_loss/len(dataloader.dataset)
    train_accuracy = 100. * train_running_correct/len(dataloader.dataset)

    print(f"训练集 损失值: {train_loss:.4f}, 训练集 准确率: {train_accurac
y:.2f}")

    return train_loss, train_accuracy
```

接下来我们定义验证函数。验证函数与训练函数的构造类似，不同点在于，在验证函数中，我们不需要更新参数，因此不需要进行反向传播等步骤。

```
# 验证函数
def validate(model, dataloader):
    print('验证')
    model.eval()
    val_running_loss = 0.0
    val_running_correct = 0
    with torch.no_grad():
        for i, data in tqdm(enumerate(dataloader), total=int(len(val_data)/da
taloader.batch_size)):
            data, target = data[0].to(device), data[1].to(device)
            outputs = model(data)
            loss = criterion(outputs, torch.max(target, 1)[1])

            val_running_loss += loss.item()
            preds = torch.max(outputs.data, 1)
```

```
            _, preds = torch.max(outputs.data, 1)
            val_running_correct += (preds == torch.max(target, 1)[1]).sum().it
em()

        val_loss = val_running_loss/len(dataloader.dataset)
        val_accuracy = 100. * val_running_correct/len(dataloader.dataset)
        print(f'验证集 损失值: {val_loss:.4f}, 验证集 准确率: {val_accurac
y:.2f}')

        return val_loss, val_accuracy
```

4 训练模型

在定义好上述函数后，我们调用这些函数，在Caltech-101数据集上进行模型的训练。

```
print(f"训练集包含 {len(train_data)} 张图像，验证集包含 {len(val_data)} 张图
像")

# 训练模型
train_loss , train_accuracy = [], []
val_loss , val_accuracy = [], []
start = time.time()
for epoch in range(epochs):
    print(f"Epoch {epoch+1} of {epochs}")

    # 调用训练函数和验证函数
    train_epoch_loss, train_epoch_accuracy = fit(model, trainloader)
    val_epoch_loss, val_epoch_accuracy = validate(model, valloader)
    train_loss.append(train_epoch_loss)
    train_accuracy.append(train_epoch_accuracy)
    val_loss.append(val_epoch_loss)
    val_accuracy.append(val_epoch_accuracy)

end = time.time()

# 显示训练模型需要的时间
print((end-start)/60, 'minutes')
```

```
  0%|          | 0/325 [00:00<?, ?it/s]

训练集包含 5205 张图像，验证集包含 1736 张图像
Epoch 1 of 5
训练

326it [01:46,  3.07it/s]
  1%|          | 1/108 [00:00<00:15,  7.11it/s]

训练集 损失值: 0.1030, 训练集 准确率: 66.95
验证

109it [00:13,  7.83it/s]
  0%|          | 0/325 [00:00<?, ?it/s]

验证集 损失值: 0.0252, 验证集 准确率: 91.47
```

```
Epoch 2 of 5
训练

326it [01:45,  3.08it/s]
  1%|          | 1/108 [00:00<00:15,  7.01it/s]

训练集 损失值: 0.0197, 训练集 准确率: 95.37
验证

109it [00:13,  7.79it/s]
  0%|          | 0/325 [00:00<?, ?it/s]

验证集 损失值: 0.0156, 验证集 准确率: 93.89
Epoch 3 of 5
训练

326it [01:45,  3.08it/s]
  1%|          | 1/108 [00:00<00:15,  6.99it/s]

训练集 损失值: 0.0061, 训练集 准确率: 98.89
验证

109it [00:13,  7.81it/s]
  0%|          | 0/325 [00:00<?, ?it/s]

验证集 损失值: 0.0108, 验证集 准确率: 95.79
Epoch 4 of 5
训练

326it [01:45,  3.08it/s]
  1%|          | 1/108 [00:00<00:15,  7.10it/s]

训练集 损失值: 0.0044, 训练集 准确率: 98.92
验证

109it [00:14,  7.78it/s]
  0%|          | 0/325 [00:00<?, ?it/s]

验证集 损失值: 0.0128, 验证集 准确率: 94.47
Epoch 5 of 5
训练

326it [01:45,  3.08it/s]
  1%|          | 1/108 [00:00<00:15,  6.98it/s]

训练集 损失值: 0.0039, 训练集 准确率: 99.10
验证

109it [00:13,  7.86it/s]

验证集 损失值: 0.0156, 验证集 准确率: 93.95
9.991878207524618 minutes
```

观察输出的结果可以发现，模型的准确率在不断提高，但评价模型的结果，也需要将损失值纳入考虑，避免模型过拟合。

5 评价模型分类效果

5.1 训练集和验证集的分类结果

下面我们通过图像，观察模型的分类效果如何。

下图展示了模型在训练集和验证集上，对图像分类的准确率。

```
# 分类准确率折线图
plt.figure(figsize=(10, 7))
plt.plot(train_accuracy, color='sandybrown', label='train accuracy')
plt.plot(val_accuracy, color='red', label='validataion accuracy')
plt.xlabel('Epochs')
plt.ylabel('Accuracy')
plt.legend()
plt.savefig('accuracy.png')
plt.show()
```

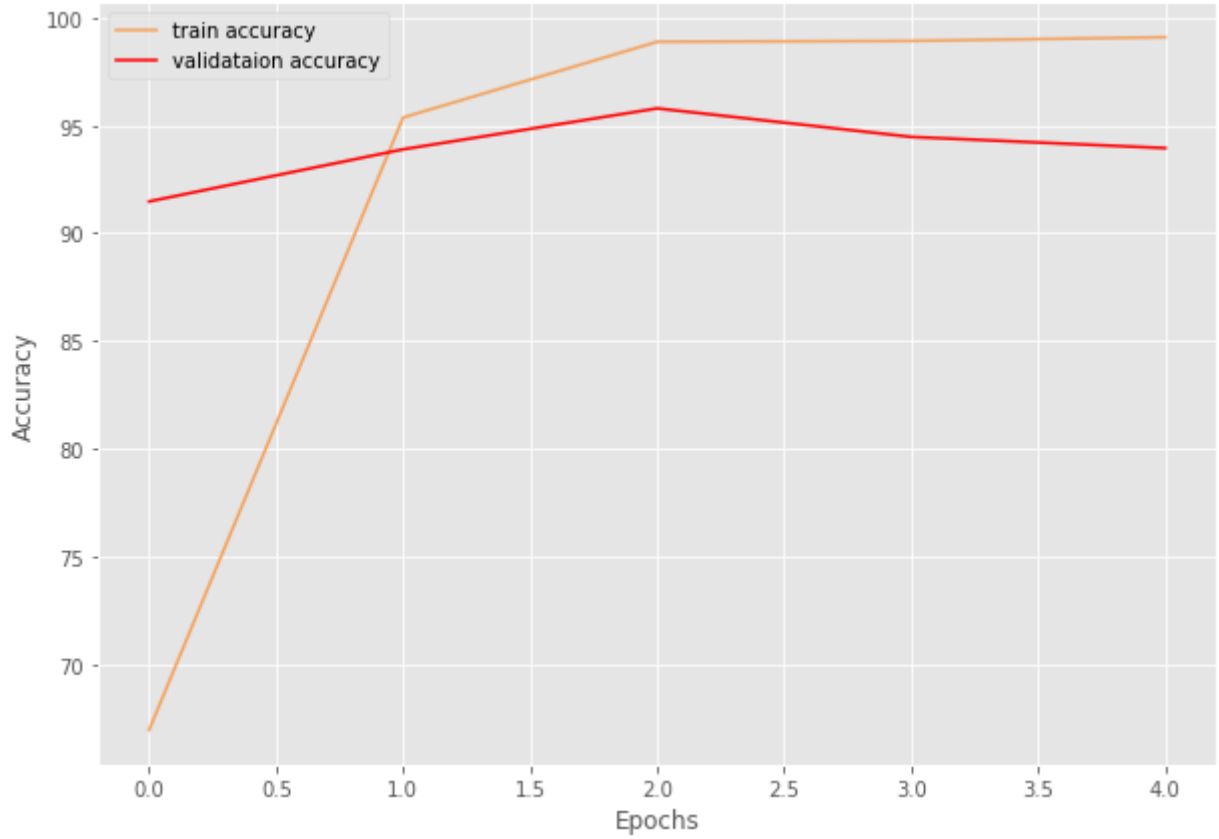

分析图像，可以明显看出，在进行3个epoch后，模型在训练集上的分类准确率仍在提升，近乎达到100%的准确率。但是模型在验证集上的准确率有下降的趋势。判断在3个epoch后，模型可能存在过拟合的情况。

再观察模型在训练集和验证集上的损失值。

```
# 损失值折线图
plt.figure(figsize=(10, 7))
plt.plot(train_loss, color='limegreen', label='train loss')
plt.plot(val_loss, color='purple', label='validataion loss')
plt.xlabel('Epochs')
plt.ylabel('Loss')
plt.legend()
plt.savefig('loss.png')
plt.show()
```

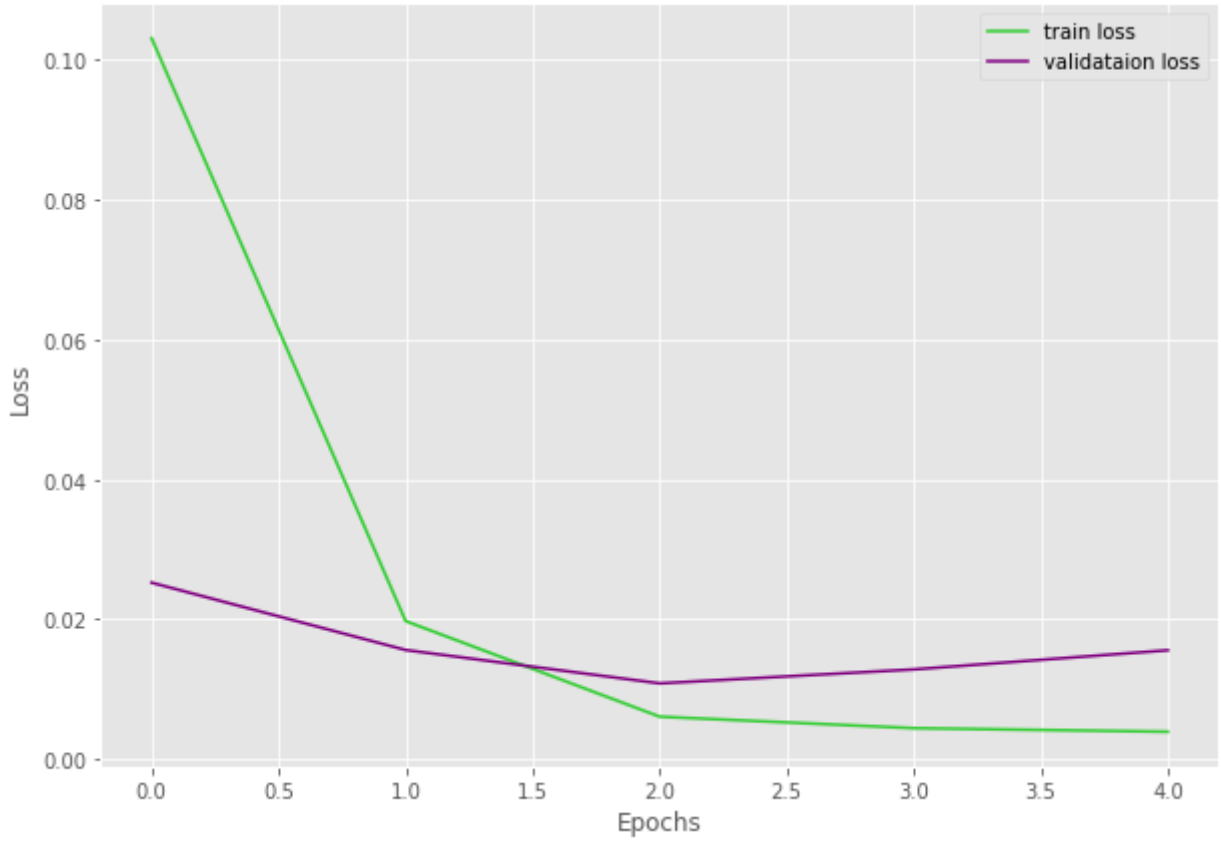

上图同样表现出，即使模型在训练集上的损失值不断降低，但在3个epoch后，模型在验证集上的损失值有增长的趋势。同样表现出模型存在过拟合的情况。

5.2 测试集的分类结果

最后，我们在测试集上运行模型，结果如下。多次测试后，可以得到结论：我们构造的ResNet模型对Caltech-101数据集的分类结果，可以达到95%左右的准确率。

```
correct = 0
total = 0
with torch.no_grad():
    for data in testloader:
        inputs, target = data[0].to(device, non_blocking=True), data[1].to(dev
ice, non_blocking=True)
```

```
ice, non_blocking=True)
        outputs = model(inputs)
        _, predicted = torch.max(outputs.data, 1)
        total += target.size(0)
        correct += (predicted == torch.max(target, 1)[1]).sum().item()

print('模型在测试集上的分类准确率 : %0.3f %%' % (
    100 * correct / total))
```

模型在测试集上的分类准确率 : 94.067 %

为了具体观察模型的分类效果，我们从每个训练批次（batch）中都随机提取一张图片，观察其是否被准确分类。

```
n = 0
with torch.no_grad():
    for data in testloader:
      inputs, target = data[0].to(device, non_blocking=True), data[1].to(devic
e, non_blocking=True)
      outputs = model(inputs)
      _, predicted = torch.max(outputs.data, 1)

      # 随机选取每个批次(epoch)中的一张图像，观察预测结果
      i = random.sample(range(0,15),1)
      i = i[0]

      print("图像",n); n = n+1
      print("预测图像属于:",label_names[predicted[i]],"类;"," 实际图像属于:",l
abel_names[torch.max(target, 1)[1][i]],"类")
```

```
图像 0
预测图像属于: pyramid 类;  实际图像属于: pyramid 类
图像 1
预测图像属于: pyramid 类;  实际图像属于: pyramid 类
图像 2
预测图像属于: pyramid 类;  实际图像属于: pyramid 类
图像 3
预测图像属于: pyramid 类;  实际图像属于: pyramid 类
图像 4
预测图像属于: nautilus 类;  实际图像属于: nautilus 类
图像 5
预测图像属于: pyramid 类;  实际图像属于: pyramid 类
图像 6
预测图像属于: nautilus 类;  实际图像属于: nautilus 类
图像 7
预测图像属于: pyramid 类;  实际图像属于: pyramid 类
图像 8
预测图像属于: pyramid 类;  实际图像属于: pyramid 类
图像 9
预测图像属于: pyramid 类;  实际图像属于: pyramid 类
图像 10
预测图像属于: pyramid 类;  实际图像属于: pyramid 类
图像 11
```

预测图像属于: pyramid 类； 实际图像属于: pyramid 类
图像 12
预测图像属于: pyramid 类； 实际图像属于: pyramid 类
图像 13
预测图像属于: nautilus 类； 实际图像属于: nautilus 类
图像 14
预测图像属于: nautilus 类； 实际图像属于: nautilus 类
图像 15
预测图像属于: nautilus 类； 实际图像属于: nautilus 类
图像 16
预测图像属于: pyramid 类； 实际图像属于: pyramid 类
图像 17
预测图像属于: nautilus 类； 实际图像属于: nautilus 类
图像 18
预测图像属于: nautilus 类； 实际图像属于: pyramid 类
图像 19
预测图像属于: pyramid 类； 实际图像属于: pyramid 类
图像 20
预测图像属于: pyramid 类； 实际图像属于: nautilus 类
图像 21
预测图像属于: pyramid 类； 实际图像属于: pyramid 类
图像 22
预测图像属于: pyramid 类； 实际图像属于: pyramid 类
图像 23
预测图像属于: nautilus 类； 实际图像属于: nautilus 类
图像 24
预测图像属于: nautilus 类； 实际图像属于: nautilus 类
图像 25
预测图像属于: pyramid 类； 实际图像属于: pyramid 类
图像 26
预测图像属于: nautilus 类； 实际图像属于: nautilus 类
图像 27
预测图像属于: nautilus 类； 实际图像属于: nautilus 类
图像 28
预测图像属于: pyramid 类； 实际图像属于: pyramid 类
图像 29
预测图像属于: pyramid 类； 实际图像属于: pyramid 类
图像 30
预测图像属于: pyramid 类； 实际图像属于: pyramid 类
图像 31
预测图像属于: pyramid 类； 实际图像属于: pyramid 类
图像 32
预测图像属于: pyramid 类； 实际图像属于: pyramid 类
图像 33
预测图像属于: pyramid 类； 实际图像属于: pyramid 类
图像 34
预测图像属于: pyramid 类； 实际图像属于: nautilus 类
图像 35
预测图像属于: nautilus 类； 实际图像属于: nautilus 类
图像 36
预测图像属于: pyramid 类； 实际图像属于: pyramid 类
图像 37
预测图像属于: pyramid 类； 实际图像属于: pyramid 类
图像 38
预测图像属于: nautilus 类； 实际图像属于: nautilus 类

图像 39
预测图像属于: pyramid 类; 实际图像属于: pyramid 类
图像 40
预测图像属于: pyramid 类; 实际图像属于: pyramid 类
图像 41
预测图像属于: pyramid 类; 实际图像属于: pyramid 类
图像 42
预测图像属于: pyramid 类; 实际图像属于: pyramid 类
图像 43
预测图像属于: pyramid 类; 实际图像属于: pyramid 类
图像 44
预测图像属于: pyramid 类; 实际图像属于: pyramid 类
图像 45
预测图像属于: nautilus 类; 实际图像属于: nautilus 类
图像 46
预测图像属于: nautilus 类; 实际图像属于: nautilus 类
图像 47
预测图像属于: pyramid 类; 实际图像属于: pyramid 类
图像 48
预测图像属于: nautilus 类; 实际图像属于: nautilus 类
图像 49
预测图像属于: pyramid 类; 实际图像属于: pyramid 类
图像 50
预测图像属于: pyramid 类; 实际图像属于: pyramid 类
图像 51
预测图像属于: pyramid 类; 实际图像属于: pyramid 类
图像 52
预测图像属于: pyramid 类; 实际图像属于: pyramid 类
图像 53
预测图像属于: pyramid 类; 实际图像属于: pyramid 类
图像 54
预测图像属于: nautilus 类; 实际图像属于: nautilus 类
图像 55
预测图像属于: pyramid 类; 实际图像属于: pyramid 类
图像 56
预测图像属于: pyramid 类; 实际图像属于: pyramid 类
图像 57
预测图像属于: pyramid 类; 实际图像属于: pyramid 类
图像 58
预测图像属于: pyramid 类; 实际图像属于: pyramid 类
图像 59
预测图像属于: pyramid 类; 实际图像属于: pyramid 类
图像 60
预测图像属于: pyramid 类; 实际图像属于: pyramid 类
图像 61
预测图像属于: nautilus 类; 实际图像属于: nautilus 类
图像 62
预测图像属于: pyramid 类; 实际图像属于: pyramid 类
图像 63
预测图像属于: pyramid 类; 实际图像属于: pyramid 类
图像 64
预测图像属于: pyramid 类; 实际图像属于: pyramid 类
图像 65
预测图像属于: pyramid 类; 实际图像属于: pyramid 类
图像 66

预测图像属于: nautilus 类； 实际图像属于: nautilus 类
图像 67
预测图像属于: pyramid 类； 实际图像属于: pyramid 类
图像 68
预测图像属于: pyramid 类； 实际图像属于: pyramid 类
图像 69
预测图像属于: pyramid 类； 实际图像属于: pyramid 类
图像 70
预测图像属于: nautilus 类； 实际图像属于: nautilus 类
图像 71
预测图像属于: pyramid 类； 实际图像属于: pyramid 类
图像 72
预测图像属于: nautilus 类； 实际图像属于: nautilus 类
图像 73
预测图像属于: pyramid 类； 实际图像属于: pyramid 类
图像 74
预测图像属于: pyramid 类； 实际图像属于: pyramid 类
图像 75
预测图像属于: nautilus 类； 实际图像属于: nautilus 类
图像 76
预测图像属于: nautilus 类； 实际图像属于: nautilus 类
图像 77
预测图像属于: pyramid 类； 实际图像属于: pyramid 类
图像 78
预测图像属于: pyramid 类； 实际图像属于: pyramid 类
图像 79
预测图像属于: pyramid 类； 实际图像属于: pyramid 类
图像 80
预测图像属于: nautilus 类； 实际图像属于: nautilus 类
图像 81
预测图像属于: pyramid 类； 实际图像属于: pyramid 类
图像 82
预测图像属于: nautilus 类； 实际图像属于: nautilus 类
图像 83
预测图像属于: nautilus 类； 实际图像属于: nautilus 类
图像 84
预测图像属于: nautilus 类； 实际图像属于: nautilus 类
图像 85
预测图像属于: nautilus 类； 实际图像属于: nautilus 类
图像 86
预测图像属于: nautilus 类； 实际图像属于: nautilus 类
图像 87
预测图像属于: pyramid 类； 实际图像属于: pyramid 类
图像 88
预测图像属于: nautilus 类； 实际图像属于: nautilus 类
图像 89
预测图像属于: pyramid 类； 实际图像属于: pyramid 类
图像 90
预测图像属于: nautilus 类； 实际图像属于: nautilus 类
图像 91
预测图像属于: pyramid 类； 实际图像属于: pyramid 类
图像 92
预测图像属于: nautilus 类； 实际图像属于: nautilus 类
图像 93
预测图像属于: pyramid 类； 实际图像属于: pyramid 类

```
图像 94
预测图像属于: nautilus 类;  实际图像属于: nautilus 类
图像 95
预测图像属于: pyramid 类;  实际图像属于: pyramid 类
图像 96
预测图像属于: nautilus 类;  实际图像属于: nautilus 类
图像 97
预测图像属于: pyramid 类;  实际图像属于: pyramid 类
图像 98
预测图像属于: nautilus 类;  实际图像属于: nautilus 类
图像 99
预测图像属于: nautilus 类;  实际图像属于: nautilus 类
图像 100
预测图像属于: pyramid 类;  实际图像属于: pyramid 类
图像 101
预测图像属于: pyramid 类;  实际图像属于: pyramid 类
图像 102
预测图像属于: pyramid 类;  实际图像属于: pyramid 类
图像 103
预测图像属于: pyramid 类;  实际图像属于: pyramid 类
图像 104
预测图像属于: pyramid 类;  实际图像属于: pyramid 类
图像 105
预测图像属于: pyramid 类;  实际图像属于: pyramid 类
图像 106
预测图像属于: pyramid 类;  实际图像属于: pyramid 类
图像 107
预测图像属于: pyramid 类;  实际图像属于: pyramid 类
图像 108
预测图像属于: nautilus 类;  实际图像属于: nautilus 类
```

从预测分类结果和实际分类结果的对比中，可以看到模型的分类准确率很高。

6 总结

本案例介绍了如何使用ResNet模型对Caltech-101数据集进行分类。虽然数据集存在图像较少、图像数量不平衡的问题，但通过迁移学习和微调的方法，我们仍获得了95%的分类准确率。并且通过在测试集上的分类效果可以看出，模型对图像的分类能力较好。

发表您的讨论